

YBIGTA 기초통계 과제 – 2024148025 오유림

1. 데이터 로드 및 기술통계 확인

저는 분석을 위해 seaborn 라이브러리를 사용하여 Iris 데이터셋을 불러왔으며 head()와 info() 함수를 통해 데이터의 전반적인 구조를 확인했습니다. Iris 데이터는 총 150개의 행으로 구성되어 있으며 결측치는 발견되지 않았습니다. 종별로 꽃잎의 길이에 대한 기술통계량을 산출한 결과, Setosa 종의 평균은 약 1.46cm, Versicolor 종은 약 4.26cm, Virginica 종은 약 5.55cm로 나타났습니다. 기술통계 분석을 통해 Setosa 종은 다른 두 종에 비해 평균 길이가 매우 짧고 표준편차가 0.17로 낮아서 데이터의 변동성이 작다는 특징을 확인했습니다.

2. 시각화 및 정규성, 등분산성 검정

이어서 종별 꽃잎 길이의 분포를 Boxplot으로 시각화하여 그룹 간의 차이를 검토했습니다. 그 결과 세 그룹의 중앙값은 뚜렷한 차이를 보였고 특히 Setosa 그룹은 다른 그룹과 분포가 전혀 겹치지 않는 독립된 범위를 형성하고 있었습니다. 통계적 검정의 전제 조건을 확인하기 위해서 한 Shapiro-Wilk 정규성 검정에서는 Setosa($p=0.0548$), Versicolor($p=0.1585$), Virginica($p=0.1098$) 모두 유의수준이 0.05를 넘어 정규성 가정을 만족했습니다. Levene의 등분산성 검정 결과 p-value가 0.0000으로 산출되어 그룹 간 분산이 동일하지 않은 것으로 나타났으나, 과제 지침에 따라 등분산성을 만족한다고 가정하고 분석을 진행했습니다.

3. ANOVA 가설 수립 및 차이 분석

ANOVA 가설 수립 부분에서는 세 가지 종 간의 꽃잎 길이 평균이 모두 동일하다는 귀무가설과 적어도 한 종의 평균은 다르다는 대립가설을 수립한 후 One-way ANOVA를 진행했습니다. 분석 결과 F-통계량은 1180.1612, p-value는 약 $2.8567766110e-91$ 로 계산되어 유의수준 0.05에서 귀무가설을 기각했습니다. 이는 종별로 꽃잎 길이에 통계적으로 유의미한 차이가 존재함을 증명하는 것으로 보입니다. 구체적인 차이를 확인하기 위해 Tukey HSD 사후검정을 수행한 결과 모든 종 간의 비교에서 p-adj 값이 0.000으로 나타나 모든 그룹 쌍 사이에 유의미한 평균 차이가 있음을 확인했습니다.

4. 선형 회귀 분석을 통한 수치 예측

마지막으로 꽃받침의 길이와 너비, 꽃잎의 너비를 독립 변수로 설정하여 꽃잎의 길이를 예측하는 다중 선형 회귀 모델을 구축했습니다. 전체 데이터를 8:2 비율로 분리하여 학습과 평가를 진행한 결과, 모델의 결정계수(R^2)는 0.9603으로 산출되어 매우 높은 설명력을 보였으며 평균 제곱 오차는 0.1300을 기록했습니다. 도출된 회귀 계수를 분석하면 꽃잎의 너비(1.4675)와 꽃받침의 길이(0.7228)가 증가할수록 꽃잎의 길이도 길어지는 경

향을 보였지만 꽃받침의 너비(-0.6358)는 꽃잎의 길이와 음의 관계를 가지는 것으로 나타났습니다.