

5회차 ML 과제 – 2024148025 오유림

1. 데이터 로드 및 기본 탐색

저는 우선 creditcard.csv 파일을 불러와 데이터의 전반적인 구조를 확인했습니다. 데이터의 구성을 다각도로 파악하기 위해 head(), info(), describe()를 실행한 뒤 정상 거래와 사기 거래의 건수를 확인했습니다.

```
Class
0    284315
1      492
Name: count, dtype: int64
```

2. 샘플링

사기 거래(Class=1) 데이터는 전부 유지하고, 정상 거래(Class=0) 데이터는 10,000건만을 무작위로 추출했습니다. 이 과정에서 random_state는 42로 설정하였으며 추출된 두 데이터셋을 합쳐 새로운 분석용 데이터프레임을 생성했습니다.

```
--- 샘플링 후 Class별 건수 ---
Class
0    10000
1      492
Name: count, dtype: int64

--- 샘플링 후 Class별 비율 ---
Class
0    0.953107
1    0.046893
Name: proportion, dtype: float64
```

샘플링 후 사기 거래의 비율이 약 4.69%로 조정된 것을 확인했습니다.

3. 데이터 전처리 및 데이터셋 분할

다음으로 모델의 학습 효율을 높이기 위해 특성 변수에 대한 전처리를 수행했습니다. Amount 변수만을 대상으로 StandardScaler를 적용하여 표준화를 진행하고 표준화된 값인 Amount_Scaled로 기존 변수를 대체했습니다. 이후 데이터를 특성 행렬인 X와 타겟 벡터인 y로 분리했습니다.

4. SMOTE

학습 데이터셋(X_train)에 SMOTE(Synthetic Minority Over-sampling Technique) 기법을 적용했습니다. SMOTE를 적용해야 하는 이유는 신용카드 사기 데이터처럼 사기 거래 데이터가 매우 적은 경우, 모델이 다수 클래스인 정상 거래에만 편향되게 학습될 위험이 있기 때문입니다. SMOTE는 단순히 데이터를 복제하는 것이 아니라 기존 데이터를 바탕

으로 가상의 새로운 데이터를 생성하여 모델이 사기 거래의 특징을 더 잘 학습하고 재현율을 높일 수 있게 합니다.

SMOTE 적용 전 사기 거래 건수: 394
SMOTE 적용 후 사기 거래 건수: 7999

5. 모델 학습 및 최종 평가

마지막으로 적합한 ML 모델로 Random Forest를 선정하여 학습을 진행했습니다. Random Forest는 여러 개의 의사결정 나무를 결합하여 학습하는 대표적인 앙상블 기법으로 단일 모델에 비해 과적합 방지에 유리하며 데이터의 복잡한 패턴을 안정적으로 학습할 수 있다는 장점이 있습니다. 특히 신용카드 사기 탐지와 같이 클래스 불균형이 심한 데이터셋에서도 사기 거래의 특성을 효과적으로 포착한다는 점에서 Recall, F1-score, PR-AUC 목표치를 달성하기에 가장 적합하다고 생각해서 ML 모델로 선정했습니다. 학습된 모델을 통해 테스트셋에서 예측값(y_{pred})과 예측 확률(y_{prob})을 도출했습니다. 모델의 성능을 평가하기 위해 classification_report로 Precision, Recall, F1-score를 확인하였으며, average_precision_score를 통해 PR-AUC 수치를 계산했습니다.

- Recall(재현율): 0.89로 목표치(0.80) 이상을 달성했습니다.
- F1-score: 0.92로 목표치(0.88) 이상을 달성했습니다.
- PR-AUC: 0.9537로 목표치(0.90) 이상을 달성했습니다.

--- Classification Report ---					
	precision	recall	f1-score	support	
0	0.99	1.00	1.00	2001	
1	0.95	0.89	0.92	98	
accuracy			0.99	2099	
macro avg	0.97	0.94	0.96	2099	
weighted avg	0.99	0.99	0.99	2099	
PR-AUC: 0.9537					